

Aplicación de Stochastic Production Model in Continuous Time (SPiCT) (Pedersen et al., 2017) en Sardina Austral de la XI Región

Mardones, M., Zúñiga, MJ., Pérez, MC

19 June, 2021

Contents

Breve descripción del keystone paper (Pedersen & Berg, 2016)	2
Principales supuestos y requerimiento de datos para SPiCT.	3
Carga de librerías necesarias.	4
Main assumptions and input data for SPiCT	5
Incorporando la propia data	6
Ploteando Data de Sardina Austral en la XI	8
Ahora aplico el modelo	12
Interpretando los resultados	17
Diagnostico y residuos	18
Extrear parametros estimados	19
Análisis retrospectivo	20
Escenarios de Manejo	21
Fijando parametros	26
Resultados del Stock Assessment (Variables poblacionales) con parámetros poblacionales fijos . . .	26
Diagrama de fase sardina austral	28
Tabla de resultados	30
Brechas analíticas	32

Breve descripción del keystone paper (Pedersen & Berg, 2016)

Este documento provee una guía (casi traducida de Pedersen et al., 2017) para el uso del modelo de producción estatocástico continuo en tiempo (SPiCT) y que está dividido en tres partes

Este es un documento vivo que estará en permanente cambio. Todos los avances y actualizaciones pueden ser seguidas y obtenidas de <https://github.com/DTUAqua/spict/commits/master>. El SPiCT package esta siendo activamente actualizado y se pueden reportar errores aquí: <https://github.com/DTUAqua/spict/releases>.

El modelo de excedente de producción tiene una larga historia como método para manejar las poblaciones de peces con datos limitados. Los avances recientes han arrojado modelos de producción excedente como modelos de espacio de estado que separan la variabilidad aleatoria de la dinámica del stock del error en los índices observados de biomasa. Pedersen & Berg (2016) presentan un modelo de producción excedente estocástico en tiempo continuo (SPiCT), que además de la dinámica del stock también modela la dinámica de las pesquerías. Esto permite que el error en el proceso de captura se refleje en la incertidumbre de los parámetros estimados del modelo y las cantidades de manejo.

La formulación del modelo de espacio de estado de tiempo continuo incluye la capacidad de proporcionar estimaciones de biomasa explotable y mortalidad por pesca en cualquier momento a partir de datos muestreados a intervalos arbitrarios y posiblemente irregulares.

Esta guía es un ejemplo de aplicación del modelo con los datos de la librería y también propone utilizar datos propios.

Principales supuestos y requerimiento de datos para SPiCT.

- Serie de tiempo en dato que contenga cambios forzantes en la población
- Contraste en los datos (Hilborn & Walters, 1989)

-Extreme observations or outliers in index and catch are commonly encountered problem in fisheries data (Chen et al. 1994).

Carga de librerías necesarias.

Lo primero es cargar TMB usando el GitHub usando devtools Package. Aquí se explica como; (<https://github.com/kaskr/adcomp/wiki/Download>)

```
install.packages("devtools")
install.packages("TMB")
#si hay problemas, instalarlo desde el github
devtools::install_github("kaskr/adcomp", subdir = "TMB")
```

Una vez cargado eso se llama de la misma forma al SPiCT package

```
devtools::install_github("DTUAqua/spict/spict")
#devtools::install_github("DTUAqua/spict/spict", ref = "1.2.8")
# aquí algunas dependencias también necesitan ser instaladas
install.packages("Rcpp")
install.packages("ellipse")
```

Aquí a veces hay problemas para acceder a GitHub por problemas en las credenciales. Para ello se debe obtener un token de GitHub (deben tener una cuenta) y hacer un proceso como lo planteado acá: <https://www.r-bloggers.com/using-travis-make-sure-you-use-a-github-pat/>

Una vez solucionando e instalando dependencias, llamamos las librerías:

```
library(usethis)
library(devtools)
library(ellipse)
library(spict) #comprobar esta versión de spict_v1.2.8
library(tidyverse)
library(patchwork)
```

Main assumptions and input data for SPiCT

- Catch data should be representative of both landings and bycatch. It is also possible to use landings only, but then the interpretation of the results changes. If available, seasonal catches should be used as input. Catches are assumed to be taken over a time interval (e.g. years or quarters), thus the associated time vector in SPiCT `inp$timeC` should reflect the beginning of each catch interval (e.g. 2002.25 and 2002.75 for the second and fourth quarter catches, respectively). Additionally, the vector `inp$dtc` should reflect the length of each time interval (e.g. 1 for annual and 0.25 for quarterly catches, respectively).
- Stock size indices should be in terms of biomass (not numbers) and representative of the part of the stock vulnerable to the commercial fleets, the so called exploitable stock biomass (ESB). In many cases, the gear selectivity of the commercial and scientific fleets do not coincide and thus the stock size indices have to be corrected to exclude individuals that are not represented in the commercial fleets.
- Biomass indices are assumed to be snapshots at given points in time. Therefore, the timing of survey indices `inp$timeI` has to be given as decimal years reflecting the timing of the survey (e.g. 1995.5 for the middle of the year). The timing of the survey will be matched to the closest model time which is dependent on `inp$dt euler` (see below). Commercial CPUE index should be associated with the midpoint of the interval of the corresponding catches, i.e. middle of the year if they are based on yearly aggregated catches and effort.

Incorporando la propia data

Leo el directorio donde contengo los datos. Si estoy trabajando en el proyecto solo vizualisto con 'list.file()'“

```
getwd()
setwd('~')
```

Usaré el ejemplon de datos de erizo de la zona X Norte. Este ejemplo no tiene mucho contraste de datos y veremos los problemas que ello acarrea.

Puedo tener un .txt ó un .csv pero deben ser transformados en formato lista.



```
sauxi <- read.table("Data_SAus_XI_2021.txt", sep=" ", header = T)
```

#un plot simple de indice y desembarque

```
bro <- ggplot(sauxi,aes(timeC,obsC))+
  geom_bar(stat="identity", fill="gray")+
  ylim(0, 8200) +
  xlab("") +
  ylab("Desembarque (t.)")+
  theme_bw()+
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5)) +
  scale_x_continuous(breaks = seq(from = 2006, to = 2020, by = 2))
```

```
cru <- ggplot(sauxi,aes(timeI,obsI))+
  geom_bar(stat="identity", fill="gray")+
  xlab("") +
  ylab("Biomasa Crucero (t.)")+
  theme_bw()+
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5)) +
  scale_x_continuous(breaks = seq(from = 2006, to = 2020, by = 2))
```

bro / cru



Convierto los datos como lista para ser lidos por las funciones del SPiCT

```
sauxi <- as.list(sauxi)
#compruebo
class(sauxi)
[1] "list"
```



Primero un vistazo a mis datos y compruebo el contraste, el que desde tya nos dirá que tan robusta es la estimación.

Tenga en cuenta que los datos están estructurados como una lista que contiene las entradas obsC (observaciones de captura), timeC (tiempo de oservaciones de captura), obsI (índice de observaciones) y timeI

(tiempo de observaciones de índice). Si no se especifican los tiempos se supone que la primera observación se observa en el tiempo 1 y luego secuencialmente en adelante con un paso de tiempo de un año. Por lo tanto, se recomienda especificar siempre los tiempos de observación

Ploteando Data de Sardina Austral en la XI



```
plotspict.data(sauxi)
Removing zero, negative, and NAs in I series 1
```

spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

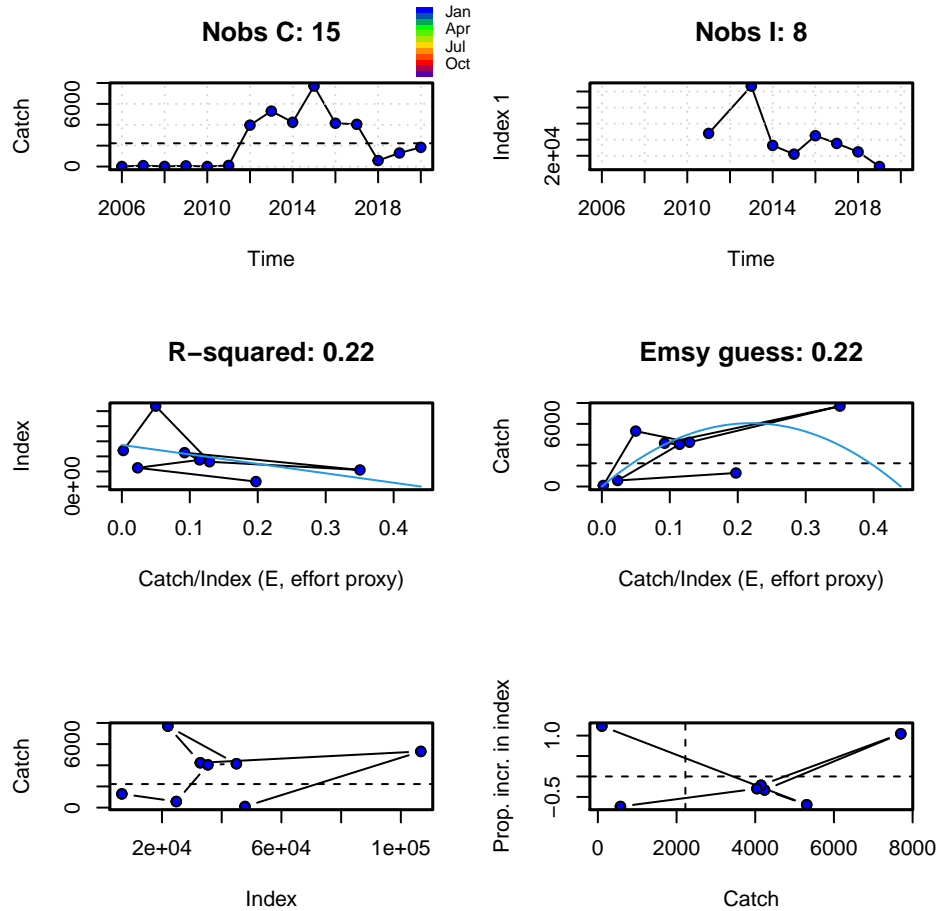
Además, el color de los puntos individuales muestra cuándo se realizó la observación en algún mes y se muestran los colores correspondientes en la leyenda de color en la esquina superior derecha. Con fines ilustrativos, intentemos cambiar un poco los datos.

```
inpshift <- sauxi
inpshift$timeC <- inpshift$timeC + 0.3 #April
inpshift$timeI <- inpshift$timeI + 0.8 #August
plotspict.data(inpshift)
  Removing zero, negative, and NAs in I series 1
```



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
plotspict.ci(sauxi)
Removing zero, negative, and NAs in I series 1
```




Las dos gráficas superiores provienen de `plotspict.data`, con la línea horizontal discontinua que representa una suposición de RMS. Esta suposición proviene de una regresión lineal entre el índice y la captura dividida por el índice (fila central, izquierda). Se espera que esta regresión tenga una pendiente negativa. Se puede hacer una gráfica similar mostrando captura versus catch / index (fila central, derecha) para encontrar aproximadamente el esfuerzo óptimo (o proxy de esfuerzo). El proporcional el aumento en el índice en función de la captura (fila inferior, derecha) debería mostrar incrementos principalmente positivos en índice de capturas bajas y viceversa.

Ahora aplico el modelo

```
resau <- fit.spict(sauxi)
  Removing zero, negative, and NAs in I series 1

plot(resau)
```




Los plot pueden ser explicados como sigue;

- Estimates (biomass, fishing mortality, catch, production) are shown using blue lines.
- 95% CIs of absolute quantities are shown using dashed blue lines.
- 95% CIs of relative biomass and fishing mortality are shown using shaded blue regions.
- Estimates of reference points (BMSY , FMSY , MSY) are shown using black lines.
- 95% CIs of reference points are shown using grey shaded regions.
- The end of the data range is shown using a vertical grey line.
- Predictions beyond the data range are shown using dotted blue lines.
- Data are shown using points colored by season. Different index series use different point characters (not shown here)


(Revisar guía Pedersen & Berg, 2017)

Cada uno de los plot se pueden sacar por separado

```
a <-plotspict.bbmsy(resau)
```




```
ab <- plotspict.ffmsy(resau)
```



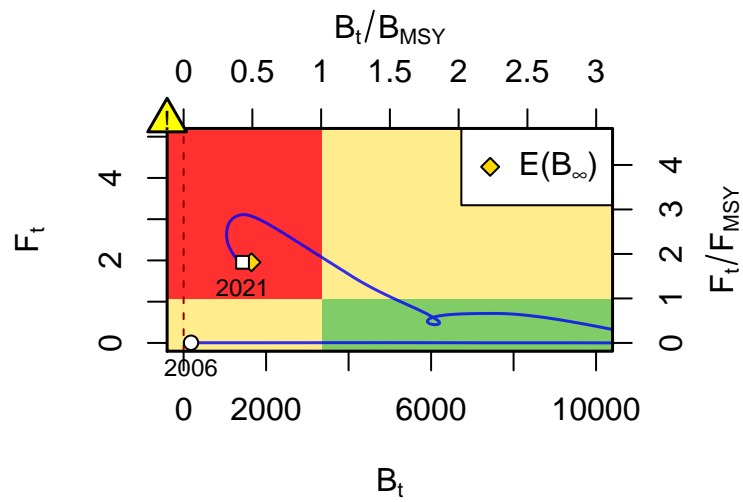
spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
b<- plotspict.biomass(resau, ylim=c(0, 8000))
```



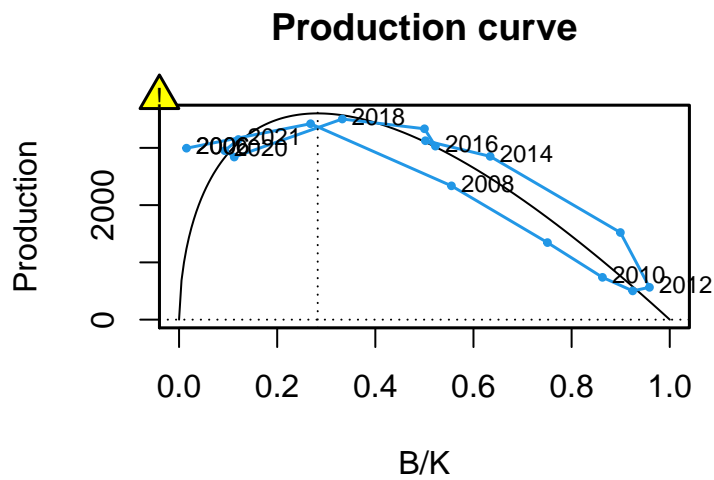
spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
d <- plotspict.fb(resau, ylim=c(0, 5), xlim=c(0, 10000))
```



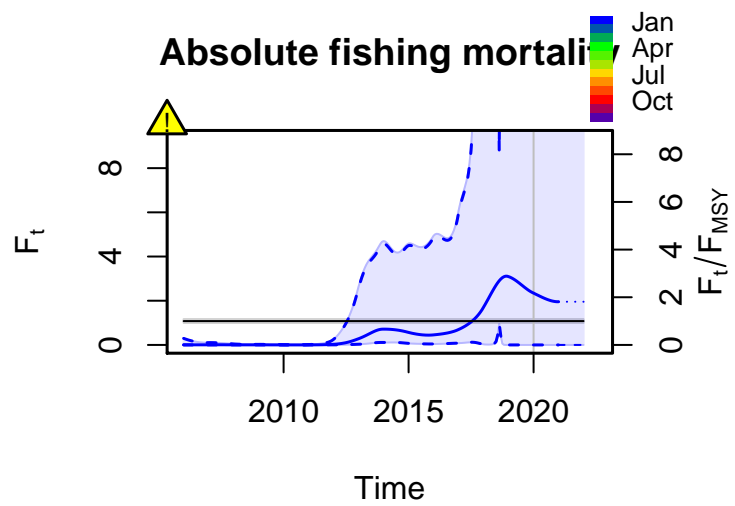
spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
da <- plotspict.production(resau)
```



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
c <- plotspict.f(resau)
```



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
#puedo hacer un layout con los graficos que quiera informar con Patchwork
a+b+c
integer(0)
```


Interpretando los resultados

```
capture.output(summary(resau))
[1] "Convergence: 1  MSG: false convergence (8)"
[2] "WARNING: Model did not obtain proper convergence! Estimates and uncertainties are most likely
[3] "Gradient at current parameter vector"
[4] "      logm      logK      logq      logn      logsdb      logsdf      "
[5] " -22.2424884   0.4457956 -15.6154028 -11.8010849  -0.2032169   6.4595507   "
[6] "      logsdi      logsdc      "
[7] "   5.6475175 -11.3944492      "
[8] ""
[9] "Objective function: 49.2473334"
[10] "Euler time step (years):  1/16 or 0.0625"
[11] "Nobs C: 15,  Nobs I1: 8"
[12] ""
[13] "Priors"
[14] "      logn ~  dnorm[log(2), 2^2]"
[15] " logalpha ~  dnorm[log(1), 2^2]"
[16] " logbeta  ~  dnorm[log(1), 2^2]"
[17] ""
[18] "Model parameter estimates w 95% CI "
[19] "      estimate      cilow      ciupp      log.est      "
[20] " alpha  5.597491e+00   2.8353997 1.105026e+01  1.7223184  "
[21] " beta   7.089571e-01   0.5355020 9.385962e-01 -0.3439603  "
[22] " r       6.620701e-01   0.5861185 7.478638e-01 -0.4123839  "
[23] " rc      2.157463e+00   1.9853406 2.344508e+00  0.7689331  "
[24] " rold    1.714091e+00   1.2432574 2.363235e+00  0.5388831  "
[25] " m       3.602382e+03 2928.8411740 4.430815e+03  8.1893504  "
[26] " K       1.181860e+04 9294.0163507 1.502896e+04  9.3774301  "
[27] " q       5.140006e+00   2.1291479 1.240856e+01  1.6370542  "
[28] " n       6.137486e-01   0.5359022 7.029032e-01 -0.4881698  "
[29] " sdb     7.561510e-02   0.0733207 7.798130e-02 -2.5820991  "
[30] " sdf     1.760461e+00   0.9729463 3.185400e+00  0.5655757  "
[31] " sdi     4.232549e-01   0.2061262 8.691020e-01 -0.8597807  "
[32] " sdc     1.248091e+00   0.5210800 2.989430e+00  0.2216155  "
[33] " "
[34] "Deterministic reference points (Drp)"
[35] "      estimate      cilow      ciupp      log.est      "
[36] " Bmsyd 3339.460334 2874.5155788 3879.608587 8.113565  "
[37] " Fmsyd   1.078732   0.9926703   1.172254 0.075786  "
[38] " MSYd  3602.381546 2928.8411740 4430.814795 8.189350  "
[39] "Stochastic reference points (Srp)"
[40] "      estimate      cilow      ciupp      log.est      rel.diff.Drp      "
[41] " Bmsys 3334.198576 2868.3879742 3875.654285 8.111988 -0.0015781179  "
[42] " Fmsys   1.078527   0.9927299   1.171739 0.075596 -0.0001899323  "
[43] " MSYs  3596.021388 2922.6702405 4424.505251 8.187583 -0.0017686653  "
[44] ""
[45] "States w 95% CI (inp$msytype: s)"
[46] "      estimate      cilow      ciupp      log.est      "
[47] " B_2020.00 1099.4700666   0 9.948868e+28 7.0025836  "
[48] " F_2020.00   2.3440921   0 4.945220e+26 0.8518982  "
[49] " B_2020.00/Bmsy 0.3297554   0 2.982565e+25 -1.1094040  "
[50] " F_2020.00/Fmsy 2.1734204   0 4.584975e+26 0.7763021  "
```

```

[51] ""
[52] "Predictions w 95% CI (inp$msytype: s)"
[53] "          prediction      cilow      ciupp      log.est  "
[54] " B_2021.00      1428.767595 0.00e+00 6.229030e+40 7.2645675  "
[55] " F_2021.00          1.954757 0.00e+00 1.060963e+32 0.6702662  "
[56] " B_2021.00/Bmsy    0.428519 0.00e+00 1.867842e+37 -0.8474201  "
[57] " F_2021.00/Fmsy    1.812433 0.00e+00 9.836938e+31 0.5946701  "
[58] " Catch_2021.00 2981.344632 2.21e-05 4.028993e+11 8.0001297  "
[59] " E(B_inf)      1645.248677      NA      NA 7.4056468  "

```

Línea 1: Convergencia del ajuste del modelo, que tiene el código 0 si el ajuste fue exitoso. Si este no es el caso no se obtuvo convergencia y los resultados informados no deben utilizarse. En caso de no convergencia, los resultados se seguirán informando para ayudar al diagnóstico del problema.

Diagnostico y residuos

Antes de proceder con los resultados para una evaluación, es muy importante que los residuos del modelo se verifiquen y se identifiquen posibles deficiencias del modelo.

Los residuos se pueden calcular usando `calc.osa.resid()`.

OSA significa un paso adelante, que son los residuos adecuados para los modelos de espacio de estado. Más información sobre los residuos de OSA está contenido en Pedersen y Berg (2017).

```

resiaus <- calc.osa.resid(resau)
plotspict.diagnostic(resiaus)

```

Extrear parametros estimados

Lo primero es ver los estimados en una lista

```
list.quantities(resau)
[1] "Bmsy"          "Bmsy2"          "BmsyB0"
[4] "Bmsyd"         "Bmsys"          "Cp"
[7] "Emsy"          "Emsy2"          "Fmsy"
[10] "Fmsyd"         "Fmsys"          "gamma"
[13] "isdb2"         "isdc2"          "isde2"
[16] "isdf2"         "isdi2"          "K"
[19] "logalpha"      "logB"           "logBBmsy"
[22] "logbeta"       "logbkfrac"      "logBl"
[25] "logBlBmsy"     "logBlK"         "logBmsy"
[28] "logBmsyd"      "logBmsyPluslogFmsy" "logBmsys"
[31] "logBp"         "logBpBmsy"      "logBpK"
[34] "logCp"         "logCpred"       "logEmsy"
[37] "logEmsy2"      "logEp"          "logF"
[40] "logFFmsy"      "logFFmsynotS"   "logFl"
[43] "logFlFmsy"     "logFmsy"        "logFmsyd"
[46] "logFmsys"      "logFnotS"       "logFp"
[49] "logFpFmsy"     "logFs"          "logIp"
[52] "logIpred"      "logK"           "logm"
[55] "logMSY"        "logMSYd"        "logMSYs"
[58] "logn"          "logq"           "logq2"
[61] "logr"          "logrc"          "logrold"
[64] "logsdb"        "logsdc"         "logsdf"
[67] "logsdi"        "m"              "MSY"
[70] "MSYd"          "MSYs"           "p"
[73] "q"             "r"              "rc"
[76] "rold"          "sdb"            "sdc"
[79] "sde"           "sdf"            "sdi"
[82] "seasonsplinefine"
```

Ahora los saco por separado

```
get.par('MSY', resau)
      ll      est      ul      sd      cv
MSY 2850.457 3596.021 4341.586 380.3901 0.1057808
```

```
get.par('logBmsy', resau)
      ll      est      ul      sd      cv
logBmsy 7.961505 8.111988 8.26247 0.07677661 0.009464587
```

Y a su vez puedo pedir el dato absoluto con exp=T

```
get.par('logBmsy', resau, exp=TRUE)
      ll      est      ul      sd      cv
logBmsy 2868.388 3334.199 3875.654 0.07677661 0.07688989
```

```
get.par('logbkfrac', resau, exp=TRUE)
      ll      est      ul      sd      cv
logbkfrac 2.065404e-07 0.01516606 1113.628 5.716364 12464701
```

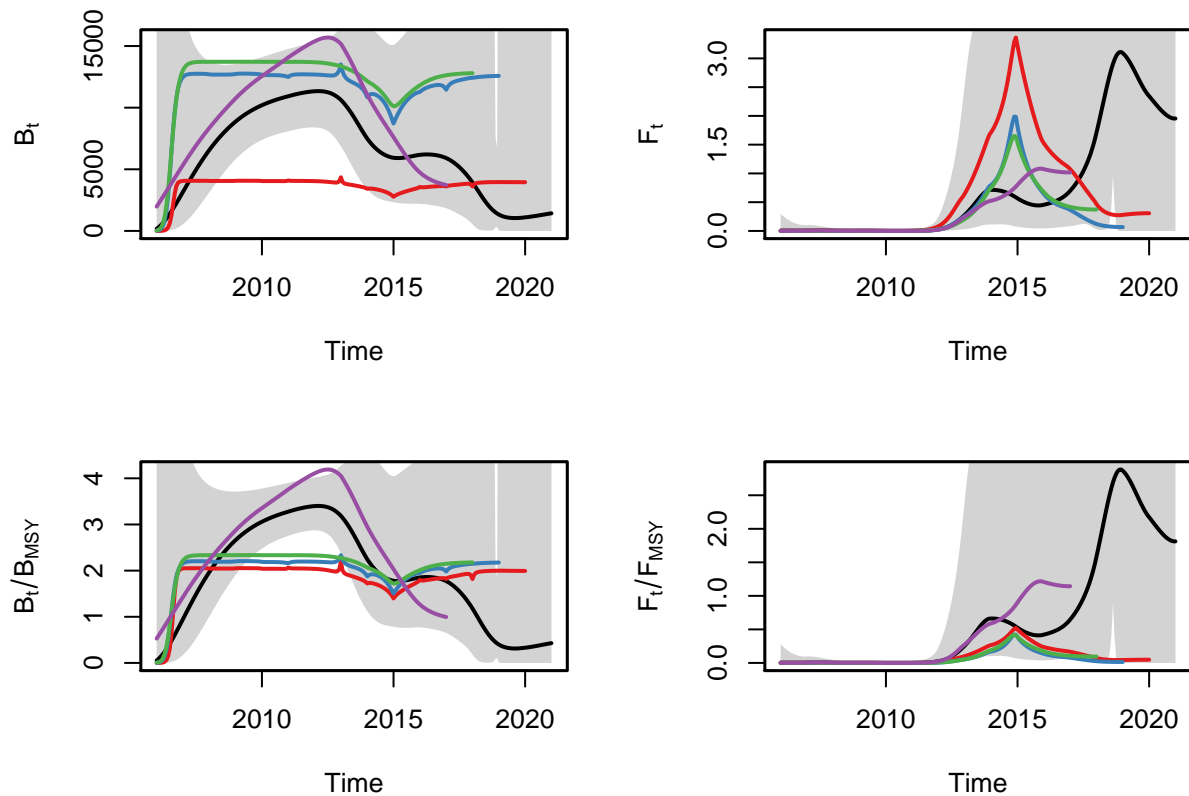
```
get.par('K', resau, exp=TRUE)
      ll est      ul      sd cv
K Inf Inf 1.505254e+306 1449.009 Inf
```

Analisis retrospectivo

Evaluar robustez de la estimación. En este caso será para 10 años.

De forma predeterminada, retro crea 5 escenarios con series de tiempo de captura e índice que se acortan del 1 al 5 al final observaciones.

```
retrosau <- retro(resau, nretroyear = 4)
plotspict.retro(retrosau)
```



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

Escenarios de Manejo

El paquete tiene una función que ejecuta varios escenarios de gestión predefinidos, que se pueden presentar en un tabla de predicción. Para realizar los cálculos necesarios para producir la ejecución de la tabla de pronóstico:

```
manesau <- manage(resau)
```

Puedo ver los resultados en la tabla con mansummary

```
mansummary(manesau)
```

```
Observed interval, index: 2011.00 - 2019.00
```

```
Observed interval, catch: 2006.00 - 2021.00
```

```
Fishing mortality (F) prediction: 2022.00
```

```
Biomass (B) prediction: 2022.00
```

```
Catch (C) prediction interval: 2021.00 - 2022.00
```

Predictions

	C	B	F	B/Bmsy	F/Fmsy	perc.dB	perc.dF
1. Keep current catch	1979.9	457.3	4.286	0.137	3.974	-73.0	154.3
2. Keep current F	3073.6	1921.6	1.685	0.575	1.563	13.5	0.0
3. Fish at Fmsy	2203.8	2235.1	1.264	0.669	1.172	32.1	-25.0
4. No fishing	6.6	4663.1	0.002	1.396	0.002	175.5	-99.9
5. Reduce F 25%	2563.3	1738.8	1.717	0.521	1.592	2.7	1.9
6. Increase F 25%	3353.8	1524.4	2.107	0.456	1.953	-9.9	25.0
7. MSY advice rule	2014.4	2477.4	1.083	0.742	1.004	46.4	-35.7

95% CIs of absolute predictions


	C.lo	C.hi	B.lo	B.hi	F.lo	F.hi
1. Keep current catch	113.3	34594.8	0.0	6.177050e+06	0	3.820849e+04
2. Keep current F	54.4	173591.3	0.0	9.016824e+15	0	6.394223e+10
3. Fish at Fmsy	119.7	40567.4	0.0	1.815859e+17	0	9.137573e+13
4. No fishing	0.0	1875.5	39.9	5.444058e+05	0	1.807081e+03
5. Reduce F 25%	7.3	900224.9	0.0	3.597296e+17	0	1.610859e+12
6. Increase F 25%	4.9	2280917.1	0.0	4.541961e+17	0	7.996908e+10
7. MSY advice rule	292.3	13881.3	0.0	1.451078e+16	0	7.834288e+13

95% CIs of relative predictions

	B/Bmsy.lo	B/Bmsy.hi	F/Fmsy.lo	F/Fmsy.hi
1. Keep current catch	0.000	3.976440e+02	0.005	3.318001e+03
2. Keep current F	0.000	2.699075e+12	0.000	5.926529e+10
3. Fish at Fmsy	0.000	5.450667e+13	0.000	8.482211e+13
4. No fishing	0.012	1.630180e+02	0.000	1.676542e+03
5. Reduce F 25%	0.000	1.075568e+14	0.000	1.493498e+12
6. Increase F 25%	0.000	1.359033e+14	0.000	7.409238e+10
7. MSY advice rule	0.000	4.348451e+12	0.000	7.267931e+13

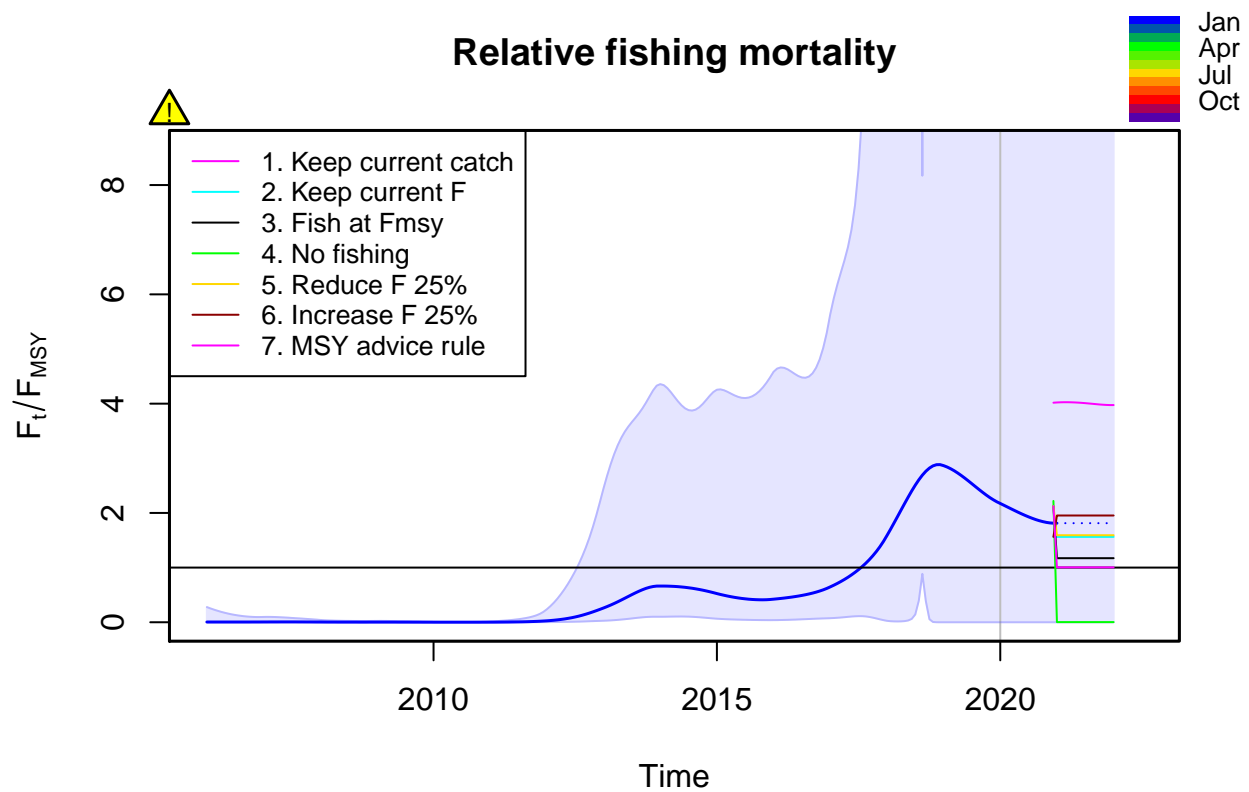
Ploteo de escenarios

```
plotspict.bbmsy(manesau)
```




spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

```
plotspict.ffmsy(manesau)
```



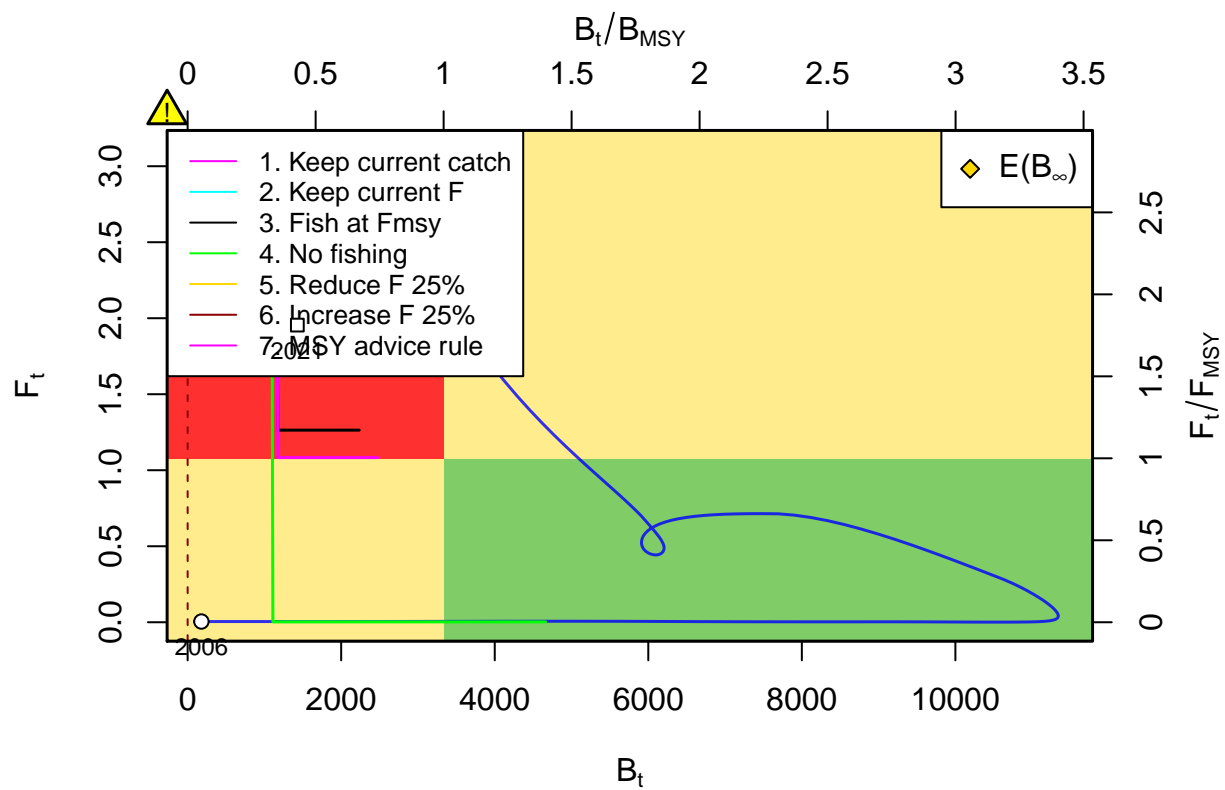
spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

`plotspict.catch(manesau)`



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

plotspict.fb(manesau)



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

Fijando parametros

Los parámetros del modelo se pueden fijar usando fases como se describió anteriormente. Esta técnica, sin embargo, solo se utiliza para fijar parámetros del modelo y, por lo tanto, no cantidades derivadas como $\log\alpha$, $\log r$ (que se deriva de $\log K$, $\log m$ y $\log n$). La fijación de un parámetro puede considerarse como una imposición de un carácter altamente informativo antes del parámetro.

Identifico los parametros que se pueden setear. Tambien es posible fijar fases de estimación.

```
list.possible.priors()
[1] "logn"      "logalpha"  "logbeta"   "logr"      "logK"      "logm"
[7] "logq"      "logqf"     "logbkfrac" "logB"      "logF"      "logBBmsy"
[13] "logFFmsy"  "logsdb"    "logsdf"    "logsdi"    "logsde"    "logsdc"
[19] "logsdm"    "logpsi"    "mu"        "BmsyB0"    "logngamma"
```

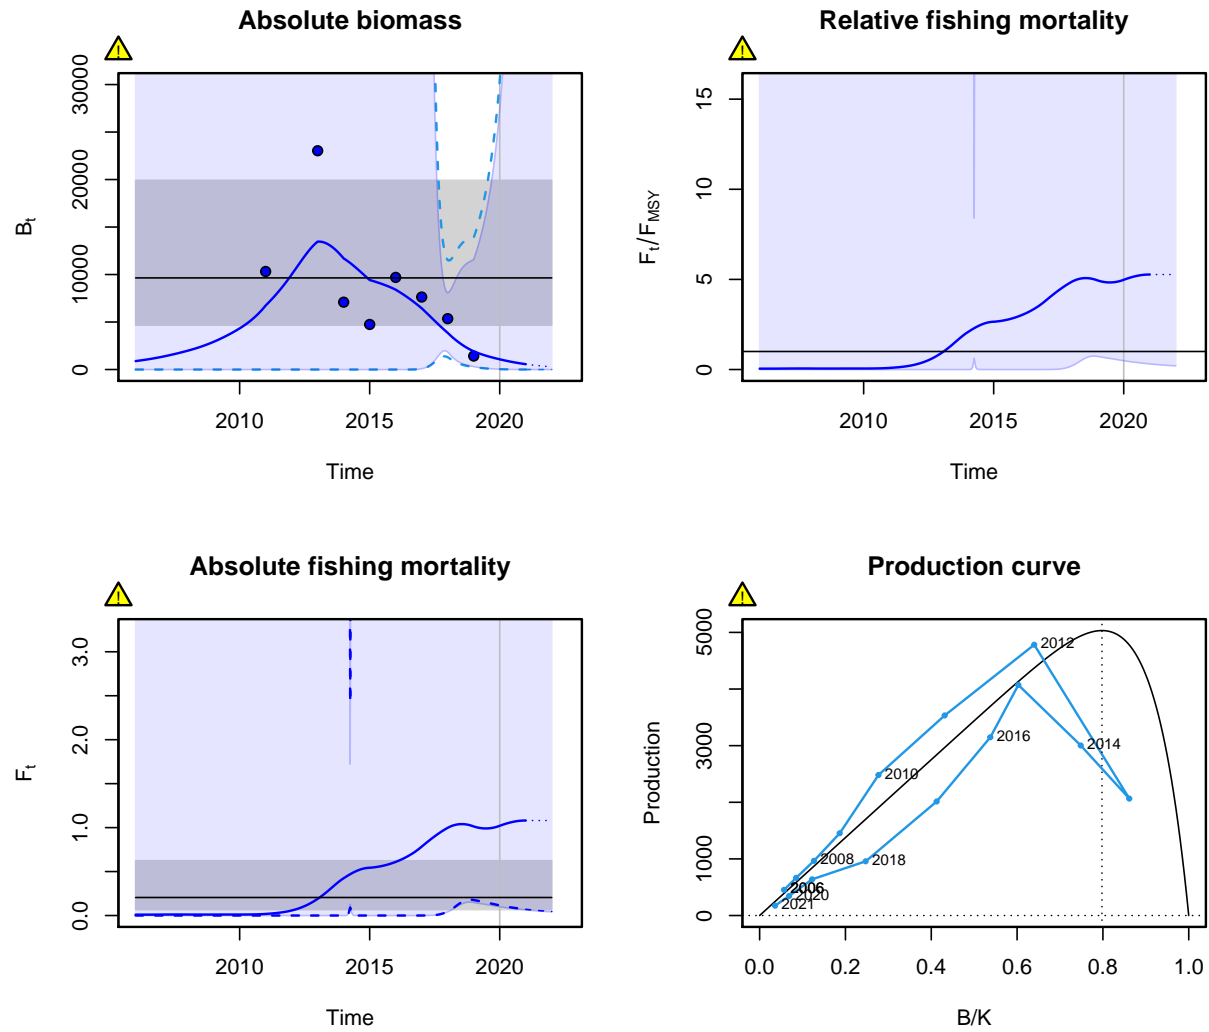
Desde ahora, haremos un “tunning” del modelo y sus condiciones iniciales para fijar ciertos parametros que permitan la estimación de las variables de interés.

```
inp <- sauxi
inp$priors$logn <- c(log(12), 1e-3)
inp$priors$logalpha <- c(log(2), 1e-3)
inp$priors$logbeta <- c(log(2), 1e-3)
resauxfix <- fit.spict(inp)
Removing zero, negative, and NAs in I series 1
```

Resultados del Stock Assessment (Variables poblacionales) con parámetros poblacionales fijos

La biomasa absoluta del stock de sardina austral para la Region de Aysén muestra un declivendesde el año 2015 cercano a las mil t., pero con un alto grado de incertidumbre de estimación. De la misma manera, el grafico superior izquierdo muestra un progresivo aumento de la mortalidad por pesca relativa a un eventual objetivo de manejo (Fmsy). Tambien es posible identificar la trayectoria de la mortalidad por pesca absoluta, que están por sobre un eventual PBR del RMS indicado en la línea negra. Además, se estima para el año 2020 un F en 1.71 años-1. Amplios intervalos de confianza como lo indica la zona sombreada de los gráficos para los parámetros estimados y la serie de tiempo de biomasa puede del proceso de ajuste y sintonización del modelo de evaluación utilizado. El grafico inferior derecho se identifica la curva de producción de la población, en donde es posible identificar que el año 2018 el stock de sardina austral estuvo en su maximo rendimiento a traves de la remoción del excedente.

\begin{figure}



{

Estimaciones SPiCT estimado en sardina austral de (a) la biomasa absoluta, (b) mortalidad por pesca relativa, (c) mortalidad por pesca absoluta y (d) curvas de producción derivadas del modelo. Las líneas (azules) indican valores medianos y áreas sombreadas en indicar intervalos de confianza (IC) del 95%. Líneas negras horizontales denotan PBR de la pesquería

}


Diagrama de fase sardina austral

La Figura x muestra la evolución de la biomasa y la mortalidad por pesca desde el año inicial (aquí 2006) indicado con un círculo hasta el año terminal (aquí 2020) indicado con un cuadrado en un esquema de fases.

El diamante amarillo indica la biomasa media durante un largo período si se mantiene la presión pesquera actual (2020). Este punto se puede interpretar como el equilibrio de captura y se denota E (B_0) en la leyenda de la figura como una forma estadística de expresar la expectativa de la biomasa como $t=0$.

De acuerdo a este diagrama, la pesquería de sardina austral estuvo sometida a bajos niveles de presión pesquera en los primeros años analizados años, por lo cual su estado representado por el diagrama de fase se encuentra en niveles subexplotados. En los años recientes esta situación cambió para pasar a una fase de sobrepesca y sobre explotación.

Una línea roja discontinua vertical en $B_t = 0$ indica el nivel de biomasa por debajo del cual la población se ha desplomado. Esta pesquería comienza en un estado de vulnerabilidad el año 2006. Es importante visualizarlos conjuntamente ya que los dos puntos de referencia están altamente (negativamente) correlacionados.



spict_v1.2.8@d9ece0a31623f1a26d3cb4328499f16136822d14

Figure 1: Diagrama de explotación B-F de sardina austral Región de Aysén durante los años 2006 y 2020. Los ejes en azul representan los límites relativos al RMS y a la mortalidad por pesca relativa al RMS para el último año (2019).

Tabla de resultados

La Tabla X muestra las estimaciones de los parámetros del modelo con Intervalos de confianza del 95% para el modelo de producción excedentaria. Hay que tener en cuenta que el intervalo de confianza para el parámetro de forma de producción n incluye el simétrico (Schaefer) caso $n = 2$. De este modelo t , no podemos decir con certeza si la producción de biomasa está sesgada. La capacidad de carga para el stock explotable se prevé que sea aproximadamente 10.02 mil t. para la curva de producción general. Sin embargo, el intervalo de dependencia es extremadamente amplio con un intervalo más bajo de 4300 t. y un intervalo superior de 135 mil t. Claramente, las predicciones del modelo están sufriendo debido a la escasez de datos y quizás a una básica sintonización del modelo. Sin embargo, el modelo proporciona una primera estimación de la abundancia absoluta. Con respecto a las variables de estado calculadas consideran un nivel de biomasa para el último año de mil t. aproximadamente.

```
[1] "Convergence: 1 MSG: false convergence (8)"
[2] "WARNING: Model did not obtain proper convergence! Estimates and uncertainties are most likely :
[3] "Gradient at current parameter vector"
[4] "      logn      logK      logq      logn      logsdb      logsdf      "
[5] " -20123464.6 100670699.0 75306631.0 11538869.9 -962590.7 -13734632.4  "
[6] "      logsdi      logsdc      "
[7] " 13823911.0 3318984.5  "
[8] ""
[9] "Objective function: 26.7625188"
[10] "Euler time step (years): 1/16 or 0.0625"
[11] "Nobs C: 15, Nobs I: 8"
[12] ""
[13] "Priors"
[14] "      logn ~ dnorm[log(12), 0.001^2] (fixed)"
[15] " logalpha ~ dnorm[log(2), 0.001^2] (fixed)"
[16] " logbeta ~ dnorm[log(2), 0.001^2] (fixed)"
[17] ""
[18] "Model parameter estimates w 95% CI "
[19] "      estimate      cilow      ciupp      log.est      "
[20] " alpha  1.999763e+00  1.9958465 2.003687e+00 0.6930288  "
[21] " beta   1.999742e+00  1.9958253 2.003666e+00 0.6930180  "
[22] " r      4.843871e+00  2.8024371 8.372386e+00 1.5777142  "
[23] " rc     8.072248e-01  0.4670108 1.395282e+00 -0.2141531  "
[24] " rold   4.403001e-01  0.2547300 7.610577e-01 -0.8202987  "
[25] " m      5.032575e+03 4490.1729224 5.640497e+03 8.5236870  "
[26] " K      1.562881e+04 7922.2268321 3.083219e+04 9.6568711  "
[27] " q      4.632102e+00  1.9257462 1.114184e+01 1.5330107  "
[28] " n      1.200129e+01 11.9777905 1.202484e+01 2.4850144  "
[29] " sdb    2.777315e-01  0.2692419 2.864887e-01 -1.2811006  "
[30] " sdf    8.179898e-01  0.7661086 8.733843e-01 -0.2009055  "
[31] " sdi    5.553971e-01  0.5383919 5.729395e-01 -0.5880718  "
[32] " sdc    1.635768e+00  1.5320945 1.746457e+00 0.4921125  "
[33] " "
[34] "Deterministic reference points (Drp)"
[35] "      estimate      cilow      ciupp      log.est      "
[36] " Bmsyd 1.246883e+04 6320.4157466 2.459834e+04 9.4309872  "
[37] " Fmsyd 4.036124e-01  0.2335054 6.976412e-01 -0.9073003  "
[38] " MSYd  5.032575e+03 4490.1729224 5.640497e+03 8.5236870  "
[39] "Stochastic reference points (Srp)"
[40] "      estimate      cilow      ciupp      log.est rel.diff.Drp  "
[41] " Bmsys 9646.5482998 4671.9215442 1.991812e+04 9.174355 -0.2925691  "
[42] " Fmsys  0.2050277  0.0674395 6.233194e-01 -1.584610 -0.9685750  "
```

```

[43] " MSYs 1417.3475568 662.8336294 3.030737e+03 7.256543 -2.5506990 "
[44] ""
[45] "States w 95% CI (inp$msytype: s)"
[46] "          estimate      cilow      ciupp    log.est  "
[47] " B_2020.00      1074.8157271 38.0543060 30357.375235 6.9799045  "
[48] " F_2020.00        1.0206757 0.1152016   9.043095 0.0204649  "
[49] " B_2020.00/Bmsy   0.1114197 0.0043876   2.829434 -2.1944509  "
[50] " F_2020.00/Fmsy   4.9782335 0.4903590  50.540132 1.6050751  "
[51] ""
[52] "Predictions w 95% CI (inp$msytype: s)"
[53] "          prediction      cilow      ciupp    log.est  "
[54] " B_2021.00      562.7493311 2.3949529 132230.91131 6.3328343  "
[55] " F_2021.00        1.0803771 0.0707603   16.49533 0.0773101  "
[56] " B_2021.00/Bmsy   0.0583369 0.0002675   12.72132 -2.8415212  "
[57] " F_2021.00/Fmsy   5.2694201 0.3134258   88.59126 1.6619203  "
[58] " Catch_2021.00  450.8216318 6.1304174  33152.74175 6.1110718  "
[59] " E(B_inf)          NaN        NA        NA        NaN  "

```

Brechas analíticas

- Como se estima F , m ?
- Como se condicionan las priors?
- predicciones. Identificar condiciones sobre las cuales se generan, por ejemplo, capturas, F , B , etc.
- Identificar claramente los escenarios por default
- Simular datos para testear
- Usar mas de un indice, incluso se puede usar el esfuerzo como indice
- Datos estacionales
-